哈尔滨工业大学深圳校区

毕业论文开题报告

题　　目　基于 Q-learning 的水下传感器网络分簇与路由算法研究

姓　　名　尹涵

学　　号　220210422

学　　院　信息科学与技术学院

专　　业　通信工程

指 导 教 师　李维

日　　期　2025 年 10 月 15 日

目　录

1　课题背景及研究的目的和意义 1
1.1　课题背景 1
1.2　研究的目的和意义 2
2　国内外研究现状及分析 4
2.1　国内外研究现状 4
2.2　国内外文献综述及简析 4
2.2.1 UWSN 分簇路由协议研究 4
2.2.2 强化学习在路由决策中的应用研究 5
2.2.3 简要评述与研究切入点 6
3　主要研究内容及研究方案 8
3.1　研究内容 8
3.1.1 设计基于 Q-learning 的自适应分簇算法 8
3.1.2 构建基于 Q-learning 的自适应路由模型 8
3.1.3 网络生命周期指标与综合奖励函数设计 9
3.1.4 算法仿真验证与性能评估 9
3.2　研究方案 9
4　进度安排及预期目标 11
4.1　进度安排 11
4.2　预期目标 11
5　已具备和所需的条件和经费 12
5.1　实验室条件和经费保障 12
5.2　所需条件和经费 12
6　预计困难及解决方案 13
6.1　预计困难与技术难点 13
6.2　解决方案 13
参考文献 15

1 课题背景及研究的目的和意义

1.1 课题背景

水下传感器网络 (Underwater Sensor Networks, UWSNs) 作为一项对海洋进行立体化、智能化观测的关键技术，正在成为现代海洋探索与开发的前沿领域。它通过在水下部署大量具备声学通信与计算能力的传感器节点，构建起一个能够实时监测、采集并传输水下环境信息的分布式网络系统。在海洋资源勘测、环境污染监测、海洋灾害预警、辅助导航乃至战术监视等军用和民用领域，UWSNs 展现出了广阔的应用前景。其典型的网络架构通常由部署在水下的传感器节点、负责汇聚数据的汇聚节点 (Sink) 以及位于水面的基站构成，基站通过无线电或卫星通信，将数据传输到最终的监控中心[1]。

然而，水下环境的独特性质，给 UWSNs 的构建与运行带来了一系列特殊且艰巨的挑战。陆地无线传感器网络（TWSNs）主要依赖电磁波进行通信，但由于电磁波在水体中会发生严重衰减，通信距离极短，UWSNs 不得不采用声波作为主要通信媒介[2]。这一物理媒介的根本性转变，使得 UWSNs 在协议层面遇到的挑战在量级和性质上都与 TWSNs 有显著区别，并由此衍生出一系列严峻的技术瓶颈：

1) 水声信道的可用带宽非常狭窄，通常只有几千赫兹，这严重限制了网络的数据传输速率。同时，复杂的海洋环境噪声和多径效应导致信道误码率极高。

2) 声波在水中的传播速度约为 1500 m/s，比电磁波慢五个数量级。这导致了极高的端到端通信延迟，并且该延迟会受到水温、盐度和深度（压力）等环境因素的影响而动态变化[3]。这种高延迟特性使得许多依赖于快速信道状态感知的陆地网络协议（如 CSMA/CA）直接失效，因为节点在发送数据前无法有效获知接收端的信道状态，从而导致严重的信道冲突。

3) 受水流、洋流等因素影响，传感器节点的位置会发生漂移，导致网络拓扑结构频繁变化，节点间的通信链路时断时续，可靠性难以保证[4]。

4) 水下传感器节点通常由电池供电，而在深水环境中对节点进行能量补充或更换电池几乎是不可能的。因此，能量效率成为 UWSNs 协议设计的首要和最关键的制约因素。

下表整理了 UWSNs 和 TWSNs 的主要不同之处：

特征	陆地无线传感器网络（TWSN）	水下传感器网络（UWSN）	对协议设计的影响
通信介质	电磁波	声波	传播速度慢 5 个数量级，延迟极高
传播延迟	低（μs）	极高（s）	传统基于载波侦听的协议失效
误码率	较低	极高	对协议的鲁棒性要求更高
节点移动性	通常静止	受水流影响，动态变化	网络拓扑频繁改变，链路不稳定
能量补充	相对容易（可更换/太阳能）	几乎不可能	能量效率成为首要制约因素
可用带宽	较宽（MHz）	极窄（kHz）	数据传输速率严重受限

正是由于上述挑战，UWSNs 中的路由问题已经不再是简单的“寻找最短路径”，而是演变为一个复杂的、以“最大化网络生命周期”为首要目标的多目标优化问题。每一次数据传输、每一次计算、甚至每一次信道监听的能量消耗，都必须与其对网络整体运行寿命的影响进行权衡。所以，分簇（Clustering）成为 UWSNs 中一种关键的网络组织方式。首先，面对严苛的能量约束，通过分簇可以将网络划分为多个区域，由簇头节点统一收集簇内成员的数据并进行融合，从而大幅减少需要进行远距离、高能耗传输的节点数量。其次，在拓扑结构频繁变化的动态环境中，分簇能够将网络的动态性限制在簇的内部，简化了路由管理和拓扑维护的复杂度，提升了网络的稳定性与可扩展性。

但是，为陆地 TWSNs 设计的经典分簇协议，如低功耗自适应分簇路由协议（LEACH），因为建立在低延迟、高带宽和稳定链路的假设之上，故而无法直接应用于水下环境。因此，研究能够适应水下信道特性、具备高能效和强鲁棒性的新型路由协议，成为 UWSNs 领域亟待解决的核心科学问题。

1.2 研究的目的和意义

本课题研究的主要目的在于，针对水下传感器网络能量受限和拓扑动态变化的核心挑战，设计并验证一种基于强化学习 Q-learning 的智能化、自适应分簇与路由算法。该算法旨在克服传统协议在簇头选举和数据转发决策上的局限性，通过统一的学习框架协同优化网络的分簇结构与数据传输路径，从而在保证数据可靠传输的前提下，最大限度地延长整个网络的生命周期。

从理论层面看，本研究的核心贡献在于将强化学习理论与无线网络协议设计进行了深度融合。它探索了在信息不完全、环境高度动态的 UWSNs 中，无模型学习算法如何有效实现网络资源的分布式、智能化管理。通过将分簇和路由两个通常被独立处理的问题置于一个统一的优化框架下，本研究为解决网络协议中的跨层联合优化问题提供了一种新的思路和理论模型。

除了理论上的创新，本研究的成果同样具备向实际应用转化的巨大潜力。一个高效、长寿的算法，能够显著提升 UWSNs 在实际海洋任务中的自主性和持久性。这意味着通过有效延长网络的工作时间，因频繁重新部署网络而产生的高昂运维成本将大幅降低，同时提升长期海洋环境监测、资源勘探等任务的数据完整性，为我国的海洋战略和蓝色经济发展提供可靠的技术支撑。

2 国内外研究现状及分析

2.1 国内外研究现状

近年来，鉴于其在科学、经济和军事领域的巨大潜力，水下传感器网络已经成为全球范围内学术界、工业界和政府研究机构的重点关注领域[5]。各国研究人员在网络体系结构、通信协议、节点定位与时间同步等方面取得了显著进展。[6]然而，如何在高动态、能量极度受限的水下环境中实现高效、可靠的数据传输，延长网络生命周期，依然是当前研究中亟待突破的难点和热点。

总体来看，国外研究起步较早，尤其在美国海军研究办公室（ONR）等机构的长期支持下，在 UWSN 的基础理论、信道建模和经典路由协议方面奠定了坚实基础[7]。其研究脉络清晰地展现了从基于地理位置的启发式路由，向基于机器学习的智能化、自适应路由演进的趋势。

国内研究虽起步稍晚，但发展极为迅速，在国家自然科学基金等项目的支持下，国内学者在改进现有协议、融合多种优化算法以及探索新型智能路由机制方面取得了丰硕成果，并在部分领域形成了自己的特色和优势 。

2.2 国内外文献综述及简析

2.2.1 UWSN 分簇路由协议研究

在 UWSN 路由协议的早期发展阶段，研究主要围绕如何将陆地无线传感器网络（TWSNs）的成功经验应用于水下环境，并针对水下特性进行适应性改造。

国外方面，研究者们率先提出了多种经典的启发式路由协议。例如，基于地理位置的向量前向路由协议 (VBF) 通过构建虚拟“管道”来约束数据包的转发范围，以降低能耗 。而在分簇路由领域，[8] LEACH 协议作为 TWSNs 的里程碑式工作，其周期性轮换簇头的思想为 UWSN 的能耗均衡研究提供了重要借鉴 。然而，早期的国际研究也深刻揭示了这些协议在水下环境中的局限性，如 VBF 在节点稀疏区易陷入“通信空洞”, 而 LEACH 的随机簇头选举机制则存在巨大的盲目性。因此，后续研究的重心转向了对这些基础协议的优化，例如，通过引入节点的剩余能量、深度信息等参数来改进簇头选举和下一跳选择的决策过程, 以应对“热点问题”和能量不均衡[9]。

国内方面，研究人员在深入分析经典协议的基础上，开展了大量的改进与创新工作。许多研究聚焦于优化 LEACH 协议的簇头选举机制，例如，李欣等学者

（2017）在专利《一种基于 leach 协议的无线传感器网络数据传输方法》中，通过设置能量阈值，并综合考虑节点的剩余能量、密度和到簇中心的距离等多个因素，来替代原有的纯概率选举模型，从而避免低能量节点过早死亡[10] 。此外，刁鹏飞等学者（2018）在《基于节点休眠的水下无线传感器网络覆盖保持分簇算法》中，针对水下网络覆盖保持的特定需求，提出了将 节点休眠/唤醒机制与分簇算法相结合的策略，在保证监测区域覆盖率的同时，让冗余节点进入休眠状态以节约能量[11]，这体现了国内研究在应用层面的精细化思考。

2.2.2 强化学习在路由决策中的应用研究

1.国内外文献综述

强化学习（Reinforcement Learning, RL）为解决动态环境下的决策优化问题提供了一种强大工具。随着研究的深入，传统启发式算法难以适应 UWSN 高度动态特性的弊端日益凸显。为此，以强化学习（RL）为代表的人工智能技术被引入路由决策领域，开启了 UWSN 路由协议“智能化”的新阶段。

国外研究在将 RL 应用于 UWSN 路由方面仍然走在前列。早在 2010 年，Yunsi Fei 等人研究出经典的 QELAR 协议，成为该领域的开创性成果。它首次将 Q-learning 应用于分布式水下路由，通过一个主要基于节点剩余能量设计的奖励函数，实现了网络负载的自适应均衡，显著延长了网络生命周期[12]。QELAR 的成功激发了后续一系列研究。而近年来的发展脉络清晰地呈现出从“单一目标”向“多目标综合优化”的演进趋势。例如，Lu Yongjie（2020）等人在《Energy-Efficient Depth-Based Opportunistic Routing with Q-Learning for Underwater Wireless Sensor Networks》中提出了 EDORQ 协议。这个协议在奖励函数中除了能量，还创新性地融入了深度信息和空洞规避因子，使得路由决策能够在能耗、时延和可靠性之间进行更全面的权衡[13]。最新的研究趋势则开始探索多智能体强化学习（MARL）的应用，将整个网络建模为一个分布式多智能体系统，通过节点间的交互与协同学习来制定路由策略，以更好地适应动态环境[4]。

国内研究在这一前沿方向上跟进迅速，并侧重于算法的融合创新与性能深化。一方面，国内学者致力于将强化学习与分簇、数据融合等其他网络技术深度结合。例如，有研究提出利用 Q-learning 来辅助选举全局最优的簇头和下一跳中继，从根源上解决“热点问题”。另一方面，国内研究在奖励函数的设计上进行了大量探索，如 Yuan Yufan（2023）在《A Q-Learning-Based Hierarchical Routing Protocol With Unequal Clustering for Underwater Acoustic Sensor Networks》中，尝试将更多维度的网络状态信息（如链路质量、数据价值等）量化地融入奖励机制，以驱动网络

实现更精细化的全局性能优化[14]。此外，将强化学习与安全路由相结合，利用信任模型来抵御恶意节点攻击，也成为国内的一个特色研究方向。

2.研究现状简析

Q-learning 是一种无模型的、基于价值迭代的强化学习算法，它允许智能体（Agent）在不具备环境先验知识的情况下，通过与环境的交互（试错）来学习最优的行为策略。其核心在于学习一个动作价值函数$Q(s,a)$，[15]这个函数会评估在状态 s 下采取动作 a 所能获得的长期累积奖励。这一特性使其非常适合 UWSNs 的动态路由决策，因为节点无需预知全局网络拓扑或信道模型，便能自主学习出最优的转发路径[16]。

将 Q-learning 应用于 UWSN 路由的基本思想是将每个传感器节点视为一个智能体，将数据包的转发决策过程建模为一个学习过程。节点通过向邻居节点发送数据包（动作），并根据转发结果（如能耗、延迟等）获得奖励或惩罚，不断更新其 Q 表，最终学习到将数据包转发给哪个邻居能够获得最高的长期收益。

在这一学习框架中，奖励函数（Reward Function）的设计是决定学习效果和网络最终行为的关键。 它为节点的每一次转发“动作”提供了即时反馈，是指导 Q 表更新和策略优化的核心信号。一个精心设计的奖励函数能够引导整个网络向着预设的全局目标（如能耗均衡、延长生命周期）演进。

纵观现有研究，其设计思路呈现出从单一目标向多目标综合优化的演进趋势：

1) 以能量为中心的奖励函数：早期的 RL 路由协议，如经典的 QELAR，开创性地将 RL 引入 UWSN 路由，其奖励函数主要围绕节点的剩余能量进行设计，旨在通过学习来均衡网络能耗，从而延长网络生命周期。

2) 多目标复合奖励函数：后续研究发现，单纯优化能量可能会导致选择高延迟或低可靠性的路径。因此，更先进的协议如 EDORQ 等，开始构建复合奖励函数，将节点的剩余能量、深度信息（作为朝向汇聚节点前进度的度量）、链路质量、空洞规避因子等多个指标综合考虑在内，以寻求能量、延迟和可靠性之间的平衡。

3) 强化学习与分簇的协同：近期研究开始探索将 Q-learning 与分簇机制相结合。例如，QHUC 协议利用 Q-learning 来辅助选举全局最优的簇头和下一跳中继，旨在从根源上解决热点问题 。这种思路与本课题的研究方向高度契合。

2.2.3 简要评述与研究切入点

综合现有的研究发现，分簇机制（如 LEACH）为网络提供了有效的组织结构

以均衡能耗，而强化学习（如 QELAR）为动态路由决策提供了强大的自适应能力。然而，这两者在现有研究中往往被割裂对待：分簇算法通常基于局部信息做出贪婪决策，形成相对固定的网络结构；而 RL 路由算法则在此基础上进行路径选择，其优化空间受限于预先划分的簇结构。

这种分离带来了一个固有的矛盾：分簇为了稳定和高效的簇内数据汇聚，倾向于维持一个相对静态的拓扑结构；而路由为了适应水下环境的动态性，则要求路径选择具有高度的灵活性。

因此，本研究的切入点和创新点在于：构建一个深度融合的统一框架，利用 Q-learning 的智能决策能力，同时指导网络的自适应分簇（簇头选举）和自适应路由（簇间中继选择）。在这个框架下，网络不仅能学习到最优的数据传输路径，更能学习到最优的网络拓扑结构本身。通过一个统一的、面向网络全局生命周期最大化的奖励函数，让分簇和路由两个过程协同进化，从而解决传统方法中两者相互制约的矛盾，实现网络性能的全局优化。

3 主要研究内容及研究方案

3.1 研究内容

为解决水下传感器网络中传统分簇路由算法存在的簇头选举盲目性、网络能耗不均衡等问题，本研究旨在引入强化学习机制，探索一种能够协同优化分簇结构与路由决策的智能化算法。为此，具体的研究内容将分解为以下四个部分：设计基于 Q-learning 的自适应分簇算法、构建基于 Q-learning 的自适应路由模型、网络生命周期指标与综合奖励函数设计和算法仿真验证与性能评估。

3.1.1 设计基于 Q-learning 的自适应分簇算法

研究通过设计基于 Q-learning 的自适应分簇算法，解决传统分簇算法中簇头选举的盲目性问题。研究将簇头选举过程建模为一个多智能体强化学习问题，其中每个传感器节点都是一个独立的智能体。这一思路与近年来强化学习在 UWSN 路由中的前沿探索相一致，即不再将节点视为孤立的学习单元。例如，Li 等人在其研究中明确指出，其协议的设计是“首先将网络建模为一个分布式多智能体系统，并将剩余能量和链路质量考虑到路由协议设计中，以提高对动态环境的适应性并支持延长网络寿命”[17]。这种建模方式正是本课题进行自适应分簇算法设计所遵循的核心思想。

为此，研究需要明确定义该强化学习模型的三个核心要素：状态空间（State）、动作空间（Action）和奖励函数（Reward）。

1) 状态空间 (S): 每个智能体的状态将由其自身可感知的局部信息构成，主要包括：节点的剩余能量、节点到汇聚节点的距离（可通过多跳通信或信标节点估算）、以及其邻居节点的密度[15]。

2) 动作空间 (A): 每个智能体在每一轮开始时的动作空间是离散且有限的，即选择“成为簇头候选者”或“保持为普通成员节点”。

3) 奖励函数 (R): 设计奖励函数，以激励形成能量高效且结构稳定的簇。当选举出的簇头具有较高的剩余能量、处于簇的几何中心位置，并且能够覆盖适量的成员节点时，参与决策的节点将获得正向奖励。反之，则获得负向奖励。通过 Q-learning 的迭代学习，网络将自主地学会选择最优的节点担任簇头，从而克服 LEACH 协议的随机性和盲目性[9]。

3.1.2 构建基于 Q-learning 的自适应路由模型

在网络完成分簇后，研究工作将聚焦于簇头之间的多跳数据转发路径优化。将所有簇头节点视为一个路由决策智能体网络。

1) 状态空间 (S): 状态定义为当前持有待转发数据包的簇头节点。

2) 动作空间 (A): 在某个状态下，动作集合为当前簇头的所有邻居簇头节点。

3) 奖励函数 (R): 设计一个面向全局优化的路由奖励函数，引导数据包在能耗均衡和传输效率之间取得最佳平衡。该函数将是一个综合性的效用函数，其构成因素包括：下一跳候选簇头的剩余能量、向汇聚节点方向的“前进距离”（可用深度差或地理距离差来衡量）、以及与下一跳候选簇头之间的链路质量（可基于历史通信成功率进行评估）。

3.1.3 网络生命周期指标与综合奖励函数设计

本部分是算法设计的核心，旨在将分簇和路由两个阶段的学习目标统一起来。

首先，要明确定义用于最终衡量算法性能的网络生命周期指标，主要包括：首节点死亡时间 (First Node Dies, FND) 和 半数节点死亡时间 (Half Nodes Die, HND) 。FND 反映了网络能耗的均衡性，而 HND 则衡量了网络的整体鲁棒性和持久性。

其次，建立一个统一的、层次化的综合奖励函数。底层的奖励（用于路由和分簇）将直接与上层的全局目标（最大化 FND 和 HND）相关联。该函数将以加权和的形式，量化地融合节点剩余能量、节点密度、到汇聚节点的距离等多个关键因素[13]。通过调整各因素的权重，可以灵活地平衡网络在不同阶段的优化侧重点[18]。

3.1.4 算法仿真验证与性能评估

最后，为了验证所提算法的有效性，研究将采用计算机仿真实验的方法进行性能评估。将选用 MATLAB 作为主要的算法实现和仿真平台，MATLAB 强大的矩阵运算能力和丰富的可视化工具，非常适合进行网络协议的仿真与分析。

为了客观评估算法性能，将选择两种代表性的协议作为基准：经典的 LEACH 协议 (作为传统分簇协议的代表) 和 QELAR 协议 (作为现有 RL 路由协议的代表)。此外，主要性能评估将围绕以下关键指标展开：网络生命周期（FND 和 HND）、数据包投递率（Packet Delivery Ratio, PDR）、平均端到端延迟以及网络总能耗[3]。通过在不同网络规模和节点密度下的仿真对比，全面分析本算法的优势与不足。

3.2 研究方案

为解决水下传感器网络（UWSNs）中能耗不均衡和拓扑动态变化的核心挑战，

本课题的研究方案将遵循一条从理论建模到仿真验证的系统性技术路线。首先，课题将对 UWSNs 的网络环境、节点能耗进行数学建模，并将分簇和路由问题形式化地统一在强化学习的框架之下。在此基础上，课题的核心工作是设计一个集成化的 Q-learning 算法，该算法通过精心设计的、面向网络生命周期最大化的综合奖励函数，协同优化自适应分簇（簇头选举）和自适应路由（簇间中继选择）两个关键过程。随后，将在 MATLAB 仿真平台上实现所提出的算法，并搭建包含经典 LEACH 协议和 QELAR 协议的对比实验环境。最后，通过开展大规模仿真实验，采集并对比分析网络生命周期、数据包投递率、网络能耗等多项关键性能指标，以系统性地验证本方案的有效性和先进性。

本课题的技术路线流程图如下图所示：

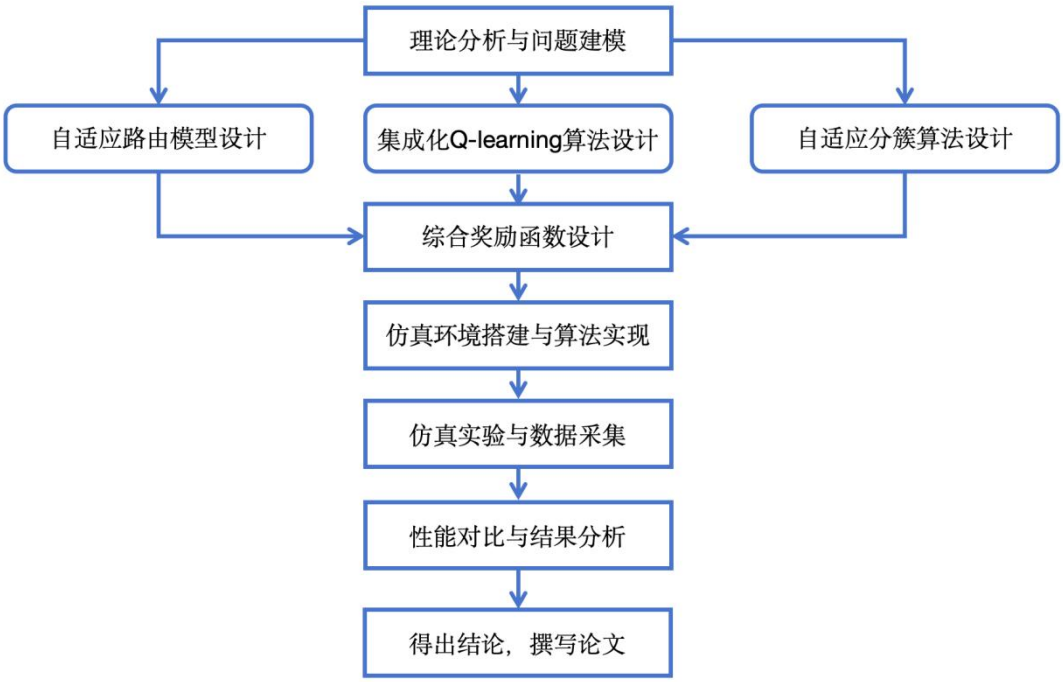

4 进度安排及预期目标

4.1 进度安排

本课题的研究周期为 2025 年 9 月至 2026 年 4 月。综合考虑课题的研究目标与内容复杂性，结合个人的学习与实践能力，现制定出如下具体的研究进度安排：

1. 2025 年 4 月 – 2025 年 10 月：开展文献调研，分析水下传感器网络自适应分簇与路由的现有方法并制定研究方案。

2. 2025 年 10 月 – 2026 年 2 月：设计并实现基于 Q-learning 的自适应分簇与路由算法，进行算法性能验证与优化。

3. 2026 年 2 月 – 2026 年 4 月：总结实验结果，分析算法性能并完成论文撰写与整理。

4.2 预期目标

通过本课题的研究，预期达成以下具体的技术与研究目标：

1. 构建一个能够将自适应分簇与自适应路由决策统一在 Q-learning 框架下的形式化模型，并完成该集成算法的详细设计，特别是其中用于指导学习的综合奖励函数。

2. 在 MATLAB 等仿真平台上，编程实现所提出的集成化 Q-learning 算法，并搭建包含经典 LEACH 协议和 QELAR 协议的对比实验环境。

3. 通过仿真实验，对所提算法在网络生命周期（如首节点死亡时间和半数节点死亡时间）、网络能耗均衡性等关键性能指标上进行评估，并与基准协议进行比较分析，以验证其在特定场景下的有效性。

5 已具备和所需的条件和经费

5.1 实验室条件和经费保障

本课题将在指导教师的悉心指导下，依托学校和学院提供的科研平台开展。指导教师在无线通信网络和人工智能领域具有丰富的研究经验，能够为本课题提供专业的理论和技术指导。此外，可通过校园网访问 IEEE Xplore、ACM Digital Library、SpringerLink、CNKI 等国内外主流学术数据库，为理论研究和文献调研提供充分保障。

5.2 所需条件和经费

研究工作主要通过软件仿真进行，核心算法的开发、实现与性能验证将在 MATLAB 等平台上完成。由于本课题涉及大规模网络仿真和强化学习算法的迭代训练，对计算性能有较高要求，所以需要高性能的计算资源。此外，本课题无需采购额外的专用硬件设备或商业软件，没有新增专项经费需求。

6 预计困难及解决方案

6.1 预计困难与技术难点

本课题高度交叉融合了水下通信、无线网络协议和强化学习三个领域。作为通信工程专业的本科生，虽然具备了通信网络的基础知识，但是对于水下声学信道这一高度专业化的领域，以及强化学习算法的理论与实践，课程体系中涉及较少，存在一定知识盲区。此外，本课题的核心验证工作依赖于 MATLAB 仿真。这不仅要求具备扎实的编程基础，更需要能够独立构建复杂的网络仿真环境，包括模拟动态的水下信道模型、节点能量消耗模型以及实现 Q-learning 智能体的学习与决策过程，这对编程实践能力提出了较高的要求。

在项目实施的具体过程中，也可能会遇到以下技术难点：

1. Q-learning 算法的性能高度依赖于奖励函数的设计。如何科学地设计一个能够平衡能量消耗、网络寿命、传输延迟等多个冲突目标的综合奖励函数，并确定各因素的最佳权重，将是本研究的核心难点。

2. Q-learning 在状态空间较大时可能面临收敛速度慢的问题。随着 UWSN 网络规模（节点数量）的增大，状态-动作空间的组合爆炸可能导致算法学习效率降低，计算开销过大。

3. 在仿真中精确地模拟水声信道的复杂特性（如时变性、多径衰落、高延迟等）有一定难度，仿真模型的逼真度将会直接影响研究结论的有效性和可靠性。

6.2 解决方案

充分预见并正视研究过程中可能出现的挑战，是确保课题顺利推进的关键。基于对个人知识储备和课题内在技术难点的深入分析，本研究已制定一套系统性的应对策略，将从个人能力提升和关键技术攻关两个层面逐一克服挑战，以保障研究目标的顺利实现。

为填补跨学科知识的空白，将采取“理论学习”与“请教交流”相结合的方式。一方面，将通过精读强化学习领域的经典教材及水下通信领域的高水平综述文献，快速构建核心知识体系。另一方面，将制定与指导教师的每周例会制度，进行专题研讨，及时扫清在自主学习过程中遇到的理论盲点和技术难题。

为应对复杂的仿真编程任务，将采用“化整为零”的软件工程思想。具体而言，

会将整个仿真系统分解为网络拓扑生成、水声信道模型、节点能耗模型、Q-learning 算法核心等多个独立模块。首先对各模块单独进行编程实现与单元测试，在确保其功能正确无误后，再进行系统集成与联合调试。这种方法可以有效降低开发难度，提高代码的可维护性与仿真平台的可靠性。

此外，针对多目标奖励函数设计的难点，将采用迭代优化的方法。初期将从一个仅考虑剩余能量的简化奖励函数入手进行实验，验证模型的基本可行性；随后，逐步引入传输延迟、链路质量等更复杂的因素，并采用网格搜索、敏感性分析等系统化的调优方法，通过大量仿真实验来寻找各因素权重参数的最优或次优组合，而非单纯依赖直觉。

最后，为确保研究结论的有效性，仿真环境的搭建将严格遵循科学标准。在水声信道模拟方面，将采用学术界公认的成熟模型（如 Urick 模型）来计算信号的传播损耗和环境噪声。同时，节点的能量消耗也将基于经典的通信能耗模型进行精确计算，从而保证仿真环境尽可能贴近真实的物理世界，提高研究结果的可信度。

参考文献

［1］苏毅珊,张贺贺,张瑞,等.水下无线传感器网络安全研究综述[J].电子与信息学报,2023,45(03):1121-1133.DOI:CNKI:SUN:DZYX.0.2023-03-039.

［2］魏志强, 杨光, 丛艳平. 水下传感器网络安全研究[J]. 计算机学报, 2012, 35(8): 1594-1603.

［3］Prathiba N, Mala C S. QLAR-Q learning based acoustic routing for underwater sensor networks[J]. Journal of Theoretical and Applied Information Technology, 2023, 101(15).

［4］Rodoshi R T, Song Y, Choi W. Reinforcement learning-based routing protocol for underwater wireless sensor networks: A comparative survey. IEEE Access, 2021.

［5］许肖梅, 孙优贤, 葛临东. 水下传感器网络研究进展. 计算机应用研究, 2007, 24(11): 1-5.

［6］桂林电子科技大学. 一种基于动态路径规划的 uwsn 传感器节点定位方法: CN111132003A[P]. 2020-05-08.

［7］Headrick, Robert & Freitag, Lee. (2009). Growth of Underwater Communication Technology in the US Navy. Communications Magazine, IEEE. 47. 80 - 82. 10.1109/MCOM.2009.4752681.

［8］Rahman, Taj, Irfan Ahmad, Asim Zeb, Inayat Khan, Gauhar Ali, and Mohammed ElAffendi. 2023. "Performance Evaluation of Routing Protocols for Underwater Wireless Sensor Networks" Journal of Marine Science and Engineering 11, no. 1: 38.

［9］贾冰 杨永健 王杰. 无线传感器网络中 LEACH 协议的改进[J]. 北京邮电大学学报, 2013, 36(1): 105-109.

［10］李欣 张林桥 张文魁. 一种基于 LEACH 协议的无线传感器网络数据传输方法: CN107529201A[P]. 2017-12-29.

［11］刁鹏飞, 王艳娇. 基于节点休眠的水下无线传感器网络覆盖保持分簇算法[J]. 电子与信息学报, 2018, 40(5): 1101-1107.

［12］Hu, Tiansi & Fei, Yunsi. (2010). QELAR: A Machine-Learning-Based Adaptive Routing Protocol for Energy-Efficient and Lifetime-Extended Underwater Sensor Networks. IEEE Trans. Mob. Comput.. 9. 796-809. 10.1109/TMC.2010.28.

［13］Lu Yongjie, Rongxi He, Xiaojing Chen, Bin Lin, and Cunqian Yu. 2020. Energy-Efficient Depth-Based Opportunistic Routing with Q-Learning for Underwater Wireless Sensor Networks.

［14］Yuan, Yufan & Liu, Meiyan & Zhuo, Xiaoxiao & Wei, Yan & Tu, Xingbin & Qu,

Fengzhong. (2023). A Q-Learning-Based Hierarchical Routing Protocol With Unequal Clustering for Underwater Acoustic Sensor Networks. IEEE Sensors Journal. PP. 1-1. 10.1109/JSEN.2022.3232614.

［15］黄鑫陈, 陈光祖, 郑敏, 等. 基于 Q-learning 的飞行自组织网络 QoS 路由方法. 中国科学院大学学报, 2022, 39(1): 134-143.

［16］Nithin, N., Rehman, S. S., Kumar, R. C. V., & Pankaj, R. N. (2024). Performance analysis of underwater wireless sensor networks using reinforcement learning. ARPN Journal of Engineering and Applied Sciences, 19(13).

［17］Li, X., Hu, X., Zhang, R., et al. (2020). Routing Protocol Design for Underwater Optical Wireless Sensor Networks: A Multiagent Reinforcement Learning Approach. IEEE Internet of Things Journal, 7(10), 9805-9818.

［18］Zhu, Rongxin, Xiwen Huang, Xiangdang Huang, Deshun Li, and Qiuling Yang. 2022. An On-Site-Based Opportunistic Routing Protocol for Scalable and Energy-Efficient Underwater Acoustic Sensor Networks. Applied Sciences 12, no. 23: 12482.